


Universidad Internacional de Valencia

Máster en Inteligencia Artificial

Trabajo Grupal - Artículo Científico - **Grupo B 23**

Asignatura: Matemáticas aplicadas a la IA



viu

Universidad
Internacional
de Valencia

Profesor: Dr. / D. Víctor Manuel Campello

Alumno 1: Unai Arambarri Yeregui

Alumno 2: Gabriel Díaz Ireland

Índice

Apartado 1: Proceso Inductivo vs Deductivo	3
Apartado 2: Ventajas de programación lógica inductiva	4
Apartado 3: Interacción de métodos inductivos con la probabilidad	5
Apartado 4: Interacción de métodos inductivos y estadísticos con la Inteligencia Artificial	6

Apartado 1: Proceso Inductivo vs Deductivo

En el artículo "INDUCTIVE LOGIC PROGRAMMING: THEORY AND METHODS" de Stephen Muggleton y Luc de Raedt se explica (página 630) la diferencia entre un proceso inductivo y deductivo.

Lógica deductiva

Desde el punto de vista computacional, los procesos deductivos son aquellos que vienen definidos por el propio programador (usuario) mediante lógicas de exclusión como son [1.1]:

- Silogismo ($\forall x (P(x) \rightarrow Q(x))$, $P(a)$, entonces $Q(a)$ es cierto)
- Modus Ponens ($P \rightarrow Q$, entonces si P entonces Q)
- Modus Tollens ($P \rightarrow Q$, entonces si $\neg P$ entonces $\neg Q$)

Estos son representados en el día a día del programador con comandos como "while", "if - ifelse - else", "switch"...

Como podemos ver, la lógica deductiva se basa en lógica de predicados no adaptable y representa leyes exactas y normas. No da pie a la experimentación y la estructura (el código en este caso) no puede cambiar la manera de clasificar o dar los resultados.

Ejemplos de lógica deductiva

Silogismo \rightarrow Todos los que son aplicados aprueban ($\forall x (P(x) \rightarrow Q(x))$). El alumno es aplicado $P(x)$. El alumno aprueba $Q(x)$.

Modus Ponens \rightarrow Si estudias entonces apruebas $P \rightarrow Q$. El alumno estudia P . El alumno aprueba Q .

Lógica inductiva

En cambio, la lógica inductiva no utiliza estas estructuras al 100% para llegar a la conclusión. En este caso se utilizan técnicas de estadística observando casos específicos, es decir, datos y ejemplos. A partir de estos datos y ejemplos, se construye una lógica en base a los patrones observados en los datos. Es decir, construye la lógica a partir de los datos.

Un ejemplo de esto es el razonamiento por analogía. Se identifican características o propiedades compartidas entre dos casos y se infiere que, si un caso tiene ciertas características y cumple ciertas condiciones, el otro caso también las tendrá. La fuerza de la conclusión depende de la relevancia y similitud de las características compartidas entre los casos.

Otros ejemplos de lógica inductiva son la generalización, predicción y la casualidad.

Como podemos observar, la lógica inductiva busca patrones a partir de un set de datos. No es una ciencia exacta, ya que estos patrones no son contruidos a partir de lógica de predicados.

Un ejemplo comparable con la vida real de lógica inductiva es el ser humano. Por ejemplo, un adolescente que crece y comienza a chocarse con el alto de las puertas. Quizá no todas las puertas sean suficientemente bajas para que la persona se choque, pero el por experiencias pasadas se agacha siempre que ve una puerta.

Si suponemos ahora una persona baja de 50 años, que se ha chocado con puertas en 4 ocasiones contadas. La quinta vez que ocurra que la puerta es lo suficientemente baja para que se choque, se chocará, ya que su red neuronal no tiene guardado el patrón si hay puerta hay que agacharse.

Ejemplos de lógica inductiva

Observación 1: Se observa que todos los estudiantes que son aplicados han aprobado ($\forall x (P(x) \rightarrow Q(x))$).

Observación 2: Se recopila información sobre el nivel de aplicación de los 50 estudiantes y se encuentra que todos ellos son aplicados ($P(x)$).

Conclusión inductiva: Se puede inferir inductivamente que es probable que todos los estudiantes aprueben ($Q(x)$). Esto se debe a la correlación observada entre ser aplicado y aprobar en todos los casos observados.

Pero ojo, esto no quiere decir que siempre vaya a ser así, ya que se construye en base a una correlación por inferencia inductiva.

Apartado 2: Ventajas de programación lógica inductiva

Para describir la motivación que nos puede llevar a usar programación inductiva nos sirve con ir al apartado anterior, en los que se ponen como ejemplo de lógica inductiva los siguientes: analogía, generalización, predicción y causalidad.

Si tomamos como, por ejemplo, la predicción, programación inductiva permite adaptar un modelo para dar respuestas en base al comportamiento de los datos y cambiar las predicciones en base a posibles fórmulas y no un solo modelo. También se puede aplicar a la programación automática, en la que, a partir de un set de datos e instrucciones de un usuario, se podría llegar a auto-escribir el código necesario [2.1].

Un ejemplo sacado de la web sería sensores con auto-aprendizaje. Pueden existir sensores de detección de objetos, detección de sonidos... Por ejemplo, el sensor de detección de sonidos captura señales de voz y utiliza programación inductiva para aprender y reconocer patrones de habla. A medida que se le proporcionan ejemplos de voz, el sensor puede aprender a identificar palabras y frases específicas [2.2].

Gracias a la programación inductiva, podríamos generar modelos autoadaptables en base a los datos que producen y que a su vez, les va llegando.

Es aquí cuando el alumno se da cuenta de que Chat GPT es un modelo basado en patrones de Deep Learning, pero que no se puede considerar un modelo de programación inductiva, ya que (pese a si ser generado mediante métodos de lógica inductiva) no es capaz de auto adaptarse de manera natural sin seguir los patrones que han sido descritos previamente en el modelo. En consecuencia, no será capaz de generar algo que no esté dentro de sus patrones de entrenamiento.

Aunque los modelos de IA pueden ser capaces de encontrar patrones y regularidades en los datos, su razonamiento y generalización difieren del enfoque inductivo humano. Los modelos de IA se centran más en el aprendizaje a partir de ejemplos y en la optimización de la precisión de las predicciones, en lugar de seguir un proceso inductivo similar al razonamiento humano. En el último apartado se entra en más detalle sobre esta relación.

Apartado 3: Interacción de métodos inductivos con la probabilidad

El proceso inductivo y la probabilidad están estrechamente relacionados ya que la inferencia inductiva a menudo se basa en la probabilidad. Por lo tanto, la probabilidad juega un papel crucial en el proceso inductivo, ya que al realizar generalizaciones o inferencias sobre una población, o al basarse en los datos de una muestra, proporciona una medida cuantitativa de la incertidumbre asociada con las inferencias.

A pesar de que en el primer apartado se haya mencionado la inferencia, cabe mencionar que se trata de un proceso mental o lógico mediante el cual se llega a una conclusión a partir de la información disponible, basándose en la evidencia, razón y lógica. Siendo la mencionada la definición, en el contexto de la IA, podríamos decir que la inferencia se refiere al proceso de utilizar un modelo entrenado para realizar predicciones o tomar decisiones basadas en nuevos datos o situaciones.

El teorema de Bayes aporta una forma de actualizar las probabilidades de unas hipótesis concretas basándose en la evidencia observada [3.1]. Por lo que al estar la probabilidad relacionada con el proceso inductivo, lo está también el teorema de Bayes. En términos simples, el teorema de Bayes proporciona una forma de calcular la probabilidad de una hipótesis dada la evidencia [3.2]. La fórmula es la siguiente:

$$P(A/B) = \frac{P(B|A) \times P(A)}{P(B)}$$

Siguiendo el ejemplo de la lógica inductiva, imagínese que, el profesor de una asignatura determinada, a partir de la experiencia previa, sabe que el 60% de los estudiantes aprueba el examen. Además, también sabe que, en general, el 75% de todos los estudiantes estudian para el examen. De aquellos que estudian, el 80% aprueba el examen. Teniendo en cuenta las probabilidades y el contexto, ¿cuál es la probabilidad de que un estudiante que ha aprobado el examen haya estudiado? En este caso, podríamos aplicar el teorema, para resolver la cuestión.

$$P(\text{Estudiar}/\text{Aprobar}) = \frac{P(\text{Aprobar}|\text{Estudiar}) \times P(\text{Estudiar})}{P(\text{Aprobar})} = \frac{0,8 \times 0,75}{0,6} = 1$$

Por lo tanto, en este caso, la probabilidad de que un estudiante que haya aprobado haya estudiado es del 100%.

En el contexto de la IA y el aprendizaje automático, la inferencia bayesiana y el teorema de Bayes son fundamentales para muchos algoritmos y métodos [3.3]. Por ejemplo, el clasificador bayesiano

ingenuo es un algoritmo de aprendizaje supervisado que se basa en la aplicación del teorema de Bayes. Los modelos gráficos bayesianos, que incluyen las redes bayesianas y las redes de Markov, son una clase de modelos que representan las dependencias entre las variables mediante un gráfico y utilizan el teorema de Bayes para realizar inferencias.

Apartado 4: Interacción de métodos inductivos y estadísticos con la Inteligencia Artificial

En los apartados anteriores se ha realizado una breve mención de la relación con la IA. Sin embargo, en este apartado se abordará con una mayor profundidad la relación entre las ramas de la lógica y estadística con la IA, y en particular el aprendizaje automático y las redes neuronales.

Como se ha mencionado (apartado 3), muchos algoritmos de aprendizaje automático se basan en principios estadísticos para hacer inferencias a partir de los datos. Por ejemplo, los algoritmos de regresión y clasificación se suelen basar en la inferencia estadística para estimar los parámetros del modelo.

Por otro lado, la lógica proporciona un marco para representar y razonar sobre el conocimiento. En la IA, los sistemas basados en lógica, como los sistemas expertos (los que usan IA para simular el razonamiento de un ser humano), utilizan la lógica para representar el conocimiento y realizar inferencias [4.1]. Por otro lado, la programación lógica inductiva es un enfoque de aprendizaje automático que combina la lógica y la inducción, utilizando la lógica para representar el conocimiento y la inducción para aprender a partir de los datos [4.2].

Las redes neuronales, son un subcampo del aprendizaje automático, también se basan en principios de lógica y estadística. Por aclarar, las redes neuronales son modelos computacionales que se inspiran en el cerebro humano y utilizan una red de nodos interconectados. Cada nodo en la red toma una serie de entradas, las pondera de acuerdo a ciertos parámetros o pesos, y produce una salida [4.3]. El aprendizaje en las redes neuronales se realiza ajustando los pesos de la red en función de los datos de entrenamiento, un proceso que se basa en principios estadísticos.

Además, existen las redes neuronales bayesianas, que combinan las redes neuronales con la inferencia bayesiana. En las redes neuronales bayesianas, los pesos de la red se tratan como variables aleatorias y se infieren utilizando técnicas de inferencia bayesiana. Esto permite a las redes neuronales bayesianas modelar la incertidumbre en los pesos de la red, lo que puede ser útil en situaciones donde los datos de entrenamiento son escasos o ruidosos [3.2].

En resumen, la lógica y la estadística, y en particular la inferencia bayesiana, son fundamentales para la inteligencia artificial y el aprendizaje automático. A pesar de que la inferencia y el razonamiento estén presentes tanto en la IA como en los humanos, se podría decir que aun siguen difiriendo de forma considerable, ya que el razonamiento humano puede ser influenciado por sesgos y emociones, mientras que el aprendizaje automático se basa en cálculos matemáticos y puede manejar grandes cantidades de datos.

Referencias adicionales

- [1.1] Reglas de inferencia lógica (Instituto Consorcio Clavijero).
- [2.1] Bratko, I., & Muggleton, S. (1995). Applications of inductive logic programming. *Communications of the ACM*, 38(11), 65-70.
- [2.2] Machine learning and computation-enabled intelligent sensor design (Ballard, 2021)
- [3.1] "Bayesian Neural Network" (Wikipedia, 2023).
- [3.2] "Probability Theory: The Logic of Science" por E. T. Jaynes (2003).
- [3.3] "Pattern Recognition and Machine Learning" por Christopher Bishop (2006).
- [4.1] Sistemas expertos: qué son, clasificación, funcionamiento (Innovación Digital 360, 2022).
- [4.2] "Inductive Logic Programming" (Wikipedia, 2023).
- [4.3] A Primer on Neural Network Models for Natural Language Processing (Goldberg, 2015).

** Se toman como en consideración de referencias base aquellas proporcionadas por el profesor para esta tarea: "INDUCTIVE LOGIC PROGRAMMING: THEORY AND METHODS", "Extending the Step-Size Restriction for Gradient Descent to Avoid Strict Saddle Points", "Bayesian Inductive Logic Programming" y "Bayesian Logic Programming: Theory and Tool".*